

Universidad de Jaén

Proyecto Interfaces de usuario multimodales



Realizada por:

Adrián Pérez Ortega(apo00015@red.ujaen.es)

Curso:

Máster Univ. en Ingeniería informática - Interfaces de usuario multimodales



Índice

Introducción al proceso de reconocimiento de texto y rostros en imágenes	3
Utilidad	5
Soluciones similares en el mercado	6
Facephi	6
Adobe	6
Tecnologías utilizadas	8
Koltin	8
ML KIT	8
AWS Rekognition	9
Cognigy	10
Casos de Uso	12
Implementación y resultados	14
Validación del documento de identidad parte delantera	14
Validación del documento de identidad parte trasera	16
Selfie y comparación de rostros	17
Síntesis de voz y reconocimiento de voz	18
Resultados finales	19
Conclusiones y autoevaluación	20
Bibliografía	22
Apéndice I. Manual de Usuario	23
Apéndice II. Descripción del contenido entregado	30



Introducción al proceso de reconocimiento de texto y rostros en imágenes

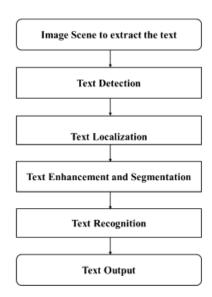
El reconocimiento de texto es una técnica analítica que consigue extraer y analizar la información que se puede identificar en diferentes imágenes. El reconocimiento de texto, se basa únicamente en la identificación de caracteres, independientemente del idioma en el que esté el texto. No obstante, lo normal es que los sistemas de reconocimiento de texto, deba de saber el alfabeto(latino, árabe, chino) del idioma como mínimo.

Además, tenemos que tener en cuenta que el proceso de reconocimiento de texto en imágenes suele ir asociado al procesado del lenguaje natural(NLP), con el fin de extraer la información relevante.

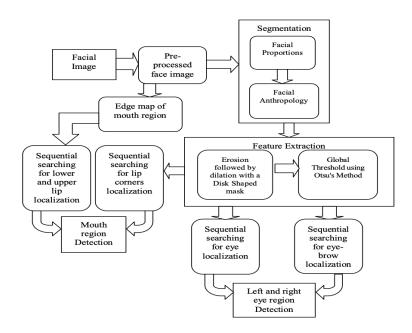
Por otro lado, las tecnologías que se utilizan para el reconocimiento de texto en imágenes son el Deep learning, sistemas de OCR y redes neuronales convolucionales(CNN).

El principal objetivo de las tecnologías de deep learning y de redes neuronales convolucionales es la de poder localizar las regiones de una imagen que contiene texto, eliminando las regiones restantes de la imagen para reducir el ruido. Una vez hecho esto, se procede a segmentar el texto e identificar los caracteres del texto.





Por otro lado, de forma similar con la utilización del machine learning se procede a la detección de rostros en imágenes.



La detección de rostros en nuestro proyecto estará centrada en detectar los bordes de la cara sin tener en cuenta características como las proporciones faciales o detección de los ojos o boca.



Utilidad

La aplicación a desarrollar puede ser de gran utilidad para:

- Reconocimiento de tarjetas de identidad.
- Facilitar el acceso a la información a personas con algún tipo de discapacidad visual.
- Validación de los datos suministrados por parte del usuario.
- Mejora en la experiencia de usuario

Esta aplicación permitirá a la empresa poder validar los documentos de identidad de los usuarios antes de ser enviados al backend o servidores externos.

Como podemos observar, a día de hoy es muy común que en diferentes situaciones sea necesario enviar algún documento de identidad(NIF, Pasaporte) a alguna entidad para acceder o solicitar algún servicio TI. Además, en muchos casos la autenticación de los datos suministrados por los usuarios referentes a su documento de identidad, suelen ser verificados y validados de forma manual, haciendo que los costes en la empresa aumente debido al personal que se dedica a dicha tarea, y haciendo que la experiencia de usuario con la entidad o aplicación en la que ha enviado las imágenes se vea reducida, ya que en muchas ocasiones los usuarios envían los datos y no es hasta pasado cierto tiempo que la entidad le devuelve una respuesta, pudiendo ser una respuesta en la que le indique que los datos han sido enviados incorrectamente.

Muchos de estos problemas, se pueden resolver si el usuario tuviese un mecanismo para comprobar si ha introducido correctamente los datos solicitados(imágenes del documento de identidad).



Soluciones similares en el mercado

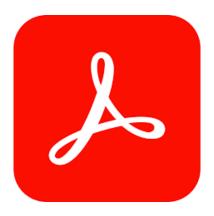
Facephi



Facephi es un servicio dedicado a la verificación de identidad del usuario, mediante el reconocimiento facial y de diferentes datos biométricos.

Facephi, es un servicio que varias empresas del sector bancario utilizan para realizar el registro y autenticación de los usuarios gracias a su servicio de identificación y procesamiento de rostros. Sin embargo FacePhi no ofrece una solución clara a la verificación de carnets de identidad, lo único que se puede hacer es comprobar la fotografía y compararla con alguna otra. Es por ello que Facephi se suele utilizar en los servicios de autenticación y no de registro.

Adobe





Adobe ofrece ciertas funcionalidades sobre el reconocimiento de texto en imágenes mediante el reconocimiento de caracteres OCR.

Estas funcionalidades permiten reconocer el texto que haya en una imagen o incluso en un video. Esta característica ofrecida por Adobe es bastante utilizada por diferentes aplicaciones, lo único que hay que hacer es realizar llamadas a la API de Rest habilitada para este servicio y enviarle las imágenes o los videos.

Obviamente, este servicio es bastante genérico y lo único que se obtiene son los caracteres que que hay en las imágenes o el en video, por lo tanto el procesamiento del texto lo tendría que realizar el cliente.

Por lo tanto, el servicio para reconocimiento de texto en imágenes y videos ofrecido por Adobe presenta varias desventajas para el caso concreto de validación y verificación de documentos de identidad.



Tecnologías utilizadas

Koltin



Kotlin es un lenguaje de programación de código abierto creado por la empresa JetBrains. Es un lenguaje de tipado estático ya que se desarrolla sobre la máquina virtual de Java(JVM) o sobre JavaScript. Además, Kotlin ha pasado a ser el lenguaje oficial de programación en Android, sustituyendo a Java.

Kotlin nos proporciona soluciones fáciles a los problemas comunes que suelen aparecer al desarrollar una aplicación móvil con Java, por ejemplo en Kotlin no existen las excepciones de NullPointerException, la cual es bastante común en Java, Kotlin nos obliga a tener controlados todos los nulos que puedan ocurrir en el programa, también tiene una curva de aprendizaje más baja que otros lenguajes como Java o C++, esto se debe a sus similitudes con Java y su simple sintaxis.

Respecto al proyecto, utilizaremos el lenguaje de programación Kotlin para el desarrollo de la app.

ML KIT



ML Kit es una librería de machine learning creada para los desarrolladores de dispositivos móviles. El Kit de AA ofrece a los desarrolladores la experiencia en



aprendizaje automático de Google en un paquete potente y fácil de usar. Las principales funcionalidades de ML Kit son:

- Escaneo de códigos de barras
- Detección de rostro
- Detección de la malla facial
- Reconocimiento de texto
- Etiquetado de imágenes
- Reconocimiento de poses
- Segmentación de selfies

Respecto al proyecto, utilizaremos la librería ML Kit para la detección de rostros y el reconocimiento de texto en imágenes.

AWS Rekognition



Amazon Rekognition facilita la incorporación del análisis de imagen y vídeo a sus aplicaciones. Proporcione una imagen o un vídeo a la API de Amazon Rekognition y el servicio podrá identificar objetos, personas, texto, escenas y actividades. Asimismo, puede detectar cualquier contenido inadecuado. Amazon Rekognition proporciona además funcionalidades de análisis, comparación y búsqueda de rostros altamente precisas. Las principales funcionalidades del servicio son:

- Detección de texto
- Etiquetado de imágenes



- Comparación de rostros
- Reconocimiento de rostros famosos

En nuestro caso utilizaremos el servicio para la funcionalidad de comparar caras.

Cognigy



Cognigy nos permite crear de forma rápida un chatbot totalmente funcional y con inteligencia artificial, el cuál podrá conversar con el usuario mediante el lenguaje natural. Esto se consigue gracias al NLU(Natural Language Understanding) que posee Cognigy, con el cuál se puede entrenar al modelo en función de oraciones de ejemplos o mediante un corpus de frases que estén clasificadas.

Para detectar las intenciones de usuario, Cognigy nos proporciona una herramienta que evalúa las diferentes frases que aporta el usuario para compararla con las oraciones de ejemplo que han sido diseñadas por los desarrolladores. Esta característica sería similar a utilizar un corpus de frases, que hubiesen sido clasificadas para la intención requerida. No obstante, Cognigy, únicamente nos exige incluir 5 frases para poder utilizar la intención, dando buen resultado con un número pequeño de frases.

Por otro lado, Cognigy, nos permite crear funciones utilizando JavaScript o TypeScript, las cuales resultan bastante útiles cuando la complejidad del problema es superior a las funciones lógicas que nos ofrece Cognigy. Además, Cognigy nos permite realizar conexiones directas a bases de datos SQL y NoSQL, como són SQL Server y MongoDB respectivamente. Aunque gracias a que Cognigy nos permite utilizar node.js,



podemos definir conexiones a otros sistemas de gestión de bases de datos como son MySQL, MariaDB o Redis, o incluso realizar llamadas a un a API de un backend para acceder a servicios y obtener la información requerida.

Cognigy, nos permite también construir diferentes test para poder probar nuestro sistema teniendo en cuenta diferentes escenarios y diferentes preguntas y respuestas. Podríamos realizar pruebas unitarias(comprobar el flujo del sistema y cómo evoluciona) y pruebas de regresión(comprobar el funcionamiento del sistema cuando ocurre un error o bug).

Para la monitorización del chatbot, Cognigy nos ofrece una sección que nos permite visualizar diferentes estadísticas sobre cómo está funcionando la aplicación. También podemos visualizar las diferentes llamadas que se hacen al chatbot, así como el número de frases que se han podido interpretar correctamente.

Para que el chatbot creado mediante Cognigy pueda interpretar las intenciones de los usuarios, utiliza el aprendizaje automático, lo cual permite al chatbot mejorar el rendimiento conforme va recibiendo preguntas y respuestas por parte de los usuarios. No obstante, para poder entrenar el chatbot es necesario suministrarle al principio unos datos entrenados.

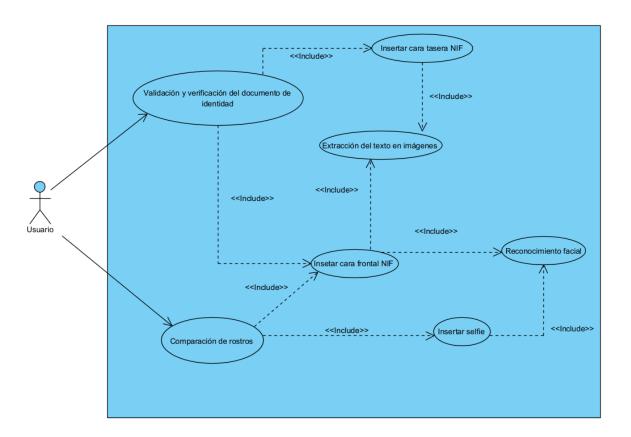
Por otro lado, el chatbot es capaz de realizar diferentes acciones con el objetivo de poder comprender mejor el contexto y las intenciones del usuario, estas acciones son:

- Reconocimiento de entidades: El chatbot podría detectar cuando la respuesta del usuario a una pregunta concreta es una entidad, por ejemplo, un número, la edad, la temperatura, una respuesta sí o no, una cantidad de dinero, etc.
- Extracción de información: El chatbot puede recibir una respuesta y mediante análisis sintácticos, análisis morfológicos y un preprocesamiento del texto puede determinar la información que quiere el usuario y así determinar su intención.



 Traducción automática de textos: Cognigy tiene la capacidad de poder traducir una frase en otro idioma, al idioma que utiliza el chatbot. No obstante, esta opción haría que el rendimiento del chatbot se redujera, una mayor complejidad del chatbot, así como un aumento en el esfuerzo para el desarrollo del chatbot.

Casos de Uso



Como podemos observar en la imagen superior, el usuario podrá realizar 2 casos de uso con la aplicación:

 Validación y verificación del documento de identidad: El usuario introducirá las imágenes del documento de identidad por delante y por detrás. Para la cara delantera del documento aplicaremos un proceso para reconocer el rostro del

Universidad de Jaén

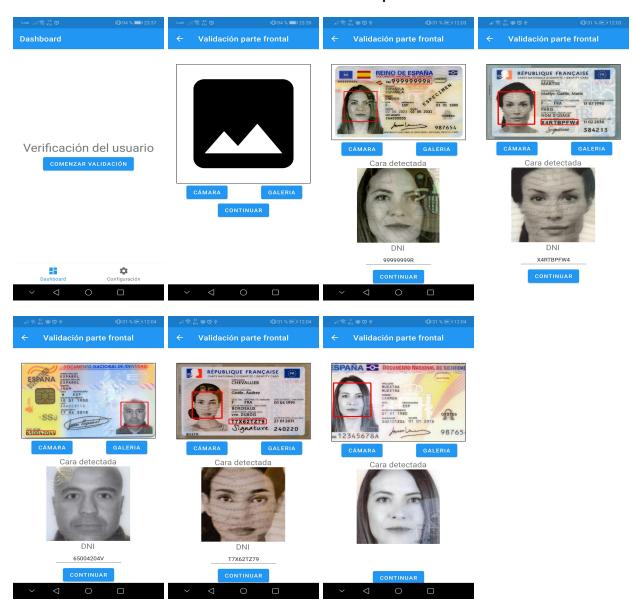
documento de identidad. Por otro lado, para ambas caras se extraerá y procesará el texto correspondiente.

Comparación de rostros: El usuario se tomará un selfie y comprobará si el
documento de identidad le pertenece. Para ello, obtendrá el rostro reconocido en
la cara frontal del dni y obtendrá el rostro reconocido del selfie que se ha
tomado.



Implementación y resultados

Validación del documento de identidad parte delantera



Como podemos ver en las imágenes superiores, al introducir una imagen del documento de identidad, ya sea desde la galería o desde la cámara, se realiza un procesamiento de la imágen para remarcar en un recuadro rojo el rostro que se ha reconocido y mostrarlo de forma separada. Por otro lado, se realiza un procesamiento

Universidad de Jaén

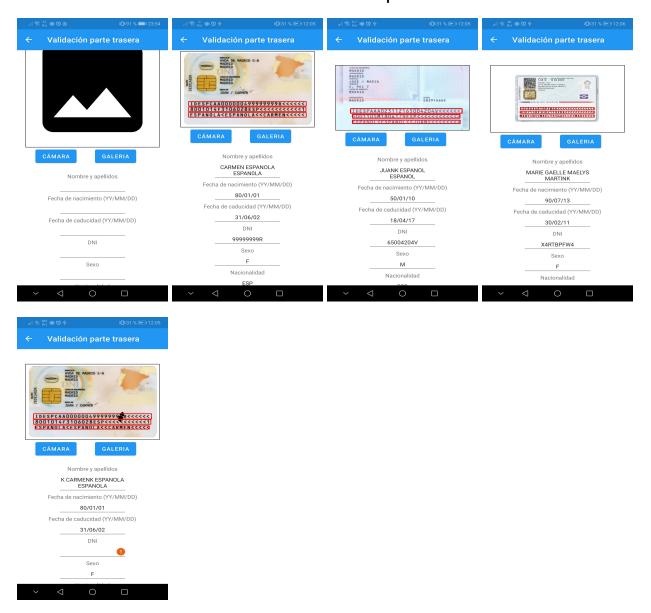
del texto para reconocer el número único identificativo de la persona. En caso de que sea válido el número de identificación se mostrará por pantalla.

En caso de que sea ínvalido el número identificativo o no se reconozca ningún rostro no se permitirá continuar.

Sobre la lógica de la pantalla, para el reconocimiento de rostros se ha utilizado la funcionalidad de detección de rostros del ML Kit [4] con la configuración predeterminada, haciendo que el sistema esté limitado a detectar únicamente una cara en la parte frontal del documento de identidad. Por otro lado, para el reconocimiento de texto se ha utilizado la funcionalidad correspondiente del ML Kit [5], la cual permite detectar el texto que hay en la imagen, se ha utilizado la configuración por defecto, indicando que el texto estará escrito con el alfabeto del latín.



Validación del documento de identidad parte trasera



Como podemos ver en las imágenes superiores, al introducir una imagen del documento de identidad de la parte trasera, ya sea desde la galería o desde la cámara, se realiza un procesamiento del texto de la imagen para reconocer los distintos campos requeridos:

- Nombre y apellidos
- Fecha de nacimiento

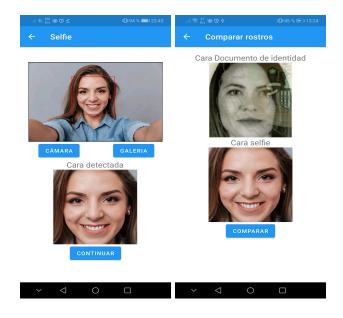


- Fecha de caducidad
- DNI
- Sexo
- Nacionalidad

Se remarcarán con un recuadro en rojo las líneas del texto que contienen dicha información. En caso de que no se pueda reconocer algún campo no se permitirá al usuario avanzar y se mostrará el error ocurrido.

De la misma forma que en la pantalla anterior, en esta se ha utilizado la funcionalidad de reconocer texto en imágenes del ML Kit, con la misma configuración.

Selfie y comparación de rostros

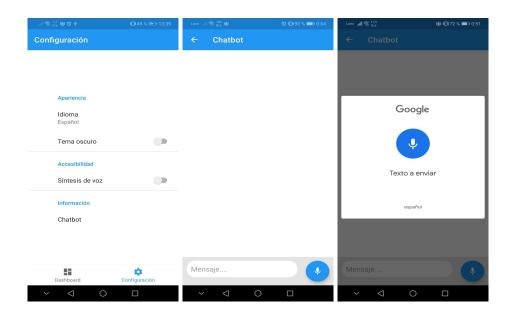


Como podemos observar en las imágenes superiores, en la primera pantalla se inserta una imagen de un selfie en la que la cara del usuario sea claramente reconocible. Una vez insertada la imagen se realiza un procesamiento de la imagen para detectar el rostro de la persona, remarcando con un recuadro en rojo y mostrándolo por pantalla. Posteriormente de haber comprobado que se ha reconocido una cara se permite pasar a la siguiente pantalla.



Por último, en la pantalla de comparación de rostros, se mostrarán los rostros detectados en la cara frontal del DNI y en el selfie tomado.

Síntesis de voz y reconocimiento de voz



Se ha implementado la funcionalidad de síntesis de voz en la que la aplicación reproducirá los campos obtenidos así como los demás mensajes que vayan apareciendo en la app. Para reproducir los mensajes se ha utilizado la librería gratuita de Android TextToSpeech [7], ya que nos ofrece la posibilidad de reproducir los mensajes que se deseen en diferentes idiomas y con diferentes entonaciones de una manera bastante sencilla e intuitiva. Por otro lado, para convertir el audio en texto se utiliza la librería SpeechRecognizer, la cual mediante Google podemos interactuar por voz con la aplicación. El único inconveniente de la librería SpeechRecognizer, es que para ser utilizada es necesaria una conexión a internet.

Además, se ha implementado un chatBot mediante la plataforma Cognigy, con el que se puede consultar diferentes características de la app y preguntar ciertas dudas. Además en la pantalla del chatBot se puede interactuar mediante la voz para convertir



el audio del usuario en texto y poder enviárselo al chatBot. Las diferentes preguntas o intenciones que podemos preguntar al chatBot, están relacionadas con:

- El desarrollador de la app.
- Solicitar asistencia de una persona física.
- Conocer cuál es el objetivo de la aplicación y su funcionalidad.
- Cómo se utiliza la aplicación.
- Cuál es el precio de la aplicación.
- Qué tipos de documentos de identidad acepta.
- Obtener información sobre los procesos del selfie y de comparar rostros.

Gracias a la implementación del chatbot mediante la plataforma de Cognigy, separamos la lógica del chatbot con la tecnología en la que se ha desarrollado la aplicación, en este caso Android y Kotlin. Por lo que si en un futuro queremos desarrollar una aplicación para dispositivos IOS o una aplicación web o asignarle algún canal como whatsapp o slack, no sería necesario crear otro chatbot, únicamente se tendría que crear el nuevo endpoints o realizar las llamadas a la API correspondiente.

Resultados finales

A continuación, se muestra un breve video en el que se puede ver el total funcionamiento del proyecto desarrollado, en el enlace https://drive.google.com/file/d/1gWmPztl2HIL0uNaZe7zTA3FAGZCTjdGw/view?usp=sharing

Por otro lado, el enlace del chatbot en la web es https://webchat-trial.cognigy.ai/v2/30e49327e003c57b894e8725cd734644c7105a9a136 d61e8bec96984863d0b2c



Conclusiones y autoevaluación

En conclusión se puede decir que se ha conseguido desarrollar un sistema capaz de validar y verificar un documento de identidad mediante la visión por computador y el posterior procesamiento del texto y caras que se obtienen en los documentos. Además se ha logrado implementar una solución capaz de detectar los rostros de personas físicas así como de realizar un procesamiento de la imagen para tratarla y remarcar la imagen seleccionada. Por otro lado, se ha logrado implementar una solución capaz de detectar el texto en una imagen y realizar su posterior procesamiento para entender el significado del texto.

Respecto a la visión por computador, no se ha conseguido implementar la comparación de rostros mediante la plataforma de AWS Rekognition, esto se debe a los diferentes problemas que nos hemos encontrado a la hora de poder conectar a la API de Rest mediante las credenciales de la cuenta de AWS.

Por otro lado, se ha conseguido con gran éxito poder implementar un sintetizador de voz gracias al cual, la aplicación podrá reproducir los mensajes y datos obtenidos al usuario. Además, se ha implementado tanto para el idioma Español como para el idioma Francés, pudiendo el usuario cambiar de idioma en la pantalla de configuración.

Respecto a la interacción por voz en la aplicación, se ha logrado implementar en la pantalla del chatBot, cierta funcionalidad en la que el usuario expresa cuál es su mensaje o duda al chatbot, y la aplicación convierte el audio de usuario en texto para enviarlo al chatBot.

Por último, la implementación de un chatBot mediante la plataforma Cognigy ha sido todo un éxito ya que se ha conseguido definir un Api de Rest para el chatBot y así mejorar la experiencia del usuario con la aplicación.



Universidad de Jaén

No obstante, la interacción por voz en la aplicación está únicamente implementada en la funcionalidad de enviar mensajes al chatBot, se podría haber añadido cierta funcionalidad para permitir realizar acciones como moverse por la aplicación o pulsar los botones mediante comandos de voz, sin embargo dicha funcionalidad requería una gran complejidad por lo que se optado por no añadirla y centrarse en el correcto funcionamiento del chatBot y de sus interacción por voz.

Por otra parte, se el chatbot implementado con Cognigy únicamente es capaz de interpretar el idioma español, se intentó añadir la funcionalidad ofrecidas por Cognigy de traducir tanto las preguntas como las respuestas, sin embargo dicha funcionalidad no se pudo lograr debido a la alta complejidad que requería.



Bibliografía

[1] Detecting faces in images: A survey (Enero de 2022) [Online], Available: https://ieeexplore--ieee--org.ujaen.debiblio.com/stamp/stamp.jsp?tp=&arnumber=98288

[2] An approach to detect de region of interest of expressive face images (Enero de 2022) [Online], Available:

https://www--sciencedirect--com.ujaen.debiblio.com/science/article/pii/S1877050915001

[3] Ejemplo de clasificador de imágenes para el seguimiento de objetos en aplicaciones nativas android [Online], Available:

https://tfhub.dev/google/lite-model/object_detection/mobile_object_labeler_v1/1

- [4] Detección de rostros con ML Kit [Online], Available: https://developers.google.com/ml-kit/vision/face-detection
- [5] Reconocimiento de texto con ML Kit [Online], Available: https://developers.google.com/ml-kit/vision/text-recognition
- [6] Documentación para implementar un asistente virtual en Cognigy [Online], Available: https://docs.cognigy.com/ai/platform-overview/
- [7] Librería TextToSpeech para reproducir mensajes [Online], Available: https://developer.android.com/reference/android/speech/tts/TextToSpeech
- [8] Librería SpeechRecognizer para interactuar por voz en la aplicación [Online],

Available: https://developer.android.com/reference/android/speech/SpeechRecognizer



Apéndice I. Manual de Usuario

En este apéndice explicaremos cómo navegar por el prototipo de aplicación móvil y utilizar las distintas funcionalidades que nos ofrece.

SplashScreen

La primera vista que nos aparecerá en el prototipo será la pantalla del splash screen durante 2 segundos. Posteriormente, se nos redirigirá a la pantalla principal, en la que habrá un menú de navegación abajo, pudiendo elegir las opciones de:

- Dashboard
- Configuración

Pantalla Principal



En la pantalla de dashboard únicamente habrá un botón en medio de la pantalla, con el cual podremos realizar el proceso de autenticación de un documento de identidad.

Al pulsar el botón se redirigirá a la ventana de validación de la cara frontal del documento de identidad.



Validación de la parte frontal



En esta pantalla se deberá de introducir una imagen del documento de identidad a validar. Para ello se puede seleccionar una imagen desde la galería o tomar una desde la cámara. Se pueden pulsar los botones correspondientes, o pulsar sobre la imágen y seleccionar la opción deseada.

Si la imágen es válida, se marcará con un recuadro rojo el rostro detectado y el número del documento de identidad. Además, se mostrará cual es el rostro detectado en la imágen y el número del documento de identidad.

En caso de que la imágen no sea válida, al pulsar el botón de continuar aparecerá una alerta indicando el error que ha ocurrido.



Validación cara Trasera



Una vez realizada con éxito la etapa de la validación de la cara frontal, se continuará con la validación de la cara trasera del documento de identidad.

Para seleccionar la imagen del documento se seleccionará una imágen de la misma manera que en la pantalla anterior. Una vez seleccionada la imágen, si se reconocen correctamente las 3 líneas que debe de tener el documento de identidad por la parte trasera, se marcarán en rojo. Además, se modificarán los campos de la pantalla en función del texto reconocido. Si todos los campos son válidos, al pulsar el botón de continuar se redirigirá a la pantalla del selfie.

En caso de que no se pueda reconocer algún campo, se marcará en rojo el campo en concreto y al pulsar el botón de continuar, se mostrará una alerta con el error correspondiente.



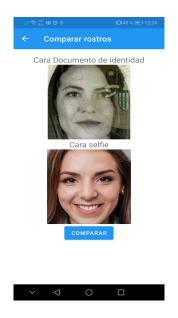
Validación selfie



Una vez realizada la validación del documento de identidad, se pasará a la pantalla de obtener un selfie del usuario. Igualmente que en las pantallas anteriores, se seleccionará una imagen de la misma manera, en la que el rostro del usuario sea visible. Si se detecta un rostro se permitirá continuar, en caso contrario al pulsar el botón de continuar se mostrará una alerta con el error correspondiente.



Comparación de rostros



La última pantalla de la validación y verificación del documento de identidad es la de comparar los rostros. En esta pantalla se muestran los rostros obtenidos en las pantalla de validación de la parte frontal y del selfie. Al pulsar el botón de comparar se debería de mostrar una ventana emergente en la que se indiquen diferentes resultados obtenidos y si son la misma persona o no. Sin embargo, no se ha podido implementar esta funcionalidad por lo que al pulsar el botón de comparar, se redirige a la pantalla principal.



Configuración



Respecto al apartado de configuración de la pantalla principal, tenemos las opciones de:

- Idioma: Seleccionar entre el idioma Español y Francés.
- Tema Oscuro: Seleccionar si se desea el tema oscuro de la aplicación.
- Síntesis de voz: Funcionalidad que permite reproducir las respuestas obtenidas de la aplicación.
- ChatBot: Funcionalidad que permite conversar con un chatBot para poder resolver ciertas dudas.



ChatBot



En la pantalla de chatBot se podrá realizar diferentes preguntas a la inteligencia artificial de la aplicación. Pudiendo escribir el mensaje mediante el teclado del dispositivo móvil o mediante una interacción por voz.



Apéndice II. Descripción del contenido entregado

A continuación comentaremos cuales son los archivos que se han adjuntado junto con la memoria del proyecto.

- Documentacion_Adrian_Perez_Ortega.pdf: documentación del proyecto de interfaces de usuario multimodales.
- proyecto_IUM.zip: archivo comprimido que contiene el código de la aplicación Kotlin.
- proyecto.apk: archivo para instalar la aplicación móvil en un dispositivo Android.